

Báo cáo Phase 1 — Chỉ mục

Người test: Sơn · Cập nhật: 2026-08-01 · Repo: <https://github.com/ahnsown/mini-world-model>

Mỗi cặp (model × dataset) một báo cáo riêng, viết theo cấu trúc 8 mục thống nhất của team.

#	Báo cáo	Model	Dataset	Độ phủ
01	Qwen2-VL-2B × MMAD	Qwen2-VL-2B-Instruct	MMAD	39,670/39,670 (100%)
02	Cosmos 3 Nano × MMAD	Cosmos 3 Nano Reasoner	MMAD	622/39,670 (1.57%)
03	Cosmos 3 Nano × HATREC	Cosmos 3 Nano Reasoner	HATREC	546/546 (100%)
04	V-JEPA 2 ViT-L × HATREC	V-JEPA 2 ViT-L 300M	HATREC	84 clip test (12 cycle)

Bảng tổng hợp chung

Model	Dataset	Metric chính	Baseline cùng dữ liệu	Thắng/Ngang/Thua	Shortcut / Leak?
Qwen2-VL-2B	MMAD (đủ 4 nguồn)	Macro-F1 0.650 · micro 64.73%	majority-letter 30.38% (F1 0.117)	THẮNG rõ ràng	Không leak protocol. Chưa test blind-image
Qwen2-VL-2B	MMAD — riêng subtask Anomaly Detection	F1 0.584 · recall 0.481	"luôn nói có lỗi" F1 0.756	THUA	Miss rate 51.9%
Cosmos3-Nano (BNB8, Kaggle T4×2)	MMAD (380 câu, chỉ MVTec-AD)	Macro-F1 0.746 · micro 73.16%	majority-letter 35.53%	THẮNG rõ ràng	Không leak. Thiên lệch độ phủ nặng
Cosmos3-Nano (endpoint chính thức)	MMAD (221 câu, chỉ MVTec-AD)	Macro-F1 0.496 · micro 49.77%	majority-letter 51.13%	THUA	như trên
Cosmos3-Nano	MMAD — riêng subtask Anomaly Detection	F1 0.250 · recall 0.143	"luôn nói có lỗi" F1 0.830	THUA nặng	Miss rate 85.7%
Cosmos3-Nano	HATREC (classification)	Macro-F1 0.216 · acc 23.63%	majority-class F1 0.036	THẮNG (nhưng không dùng được)	Không leak. Chưa test static-frame; bằng chứng thời gian chỉ 17.6%
V-JEPA 2 ViT-L (🚩 có probe, không zero-shot)	HATREC	Macro-F1 1.0 · acc 100%	majority blind F1 0.036	Thắng về số — KHÔNG TIN CẬY ĐƯỢC	Leak quy trình PASS, nhưng similarity 0.9922 + thiếu static-frame
GPT-4o (tham chiếu từ paper MMAD)	MMAD	~74.9%	—	Cao hơn nhiều model open-source	Paper có human baseline để đối chiếu

Ba kết luận cần nhấn mạnh khi trình bày

1. So sánh Cosmos vs Qwen trên MMAD phải khớp nguồn dữ liệu

Toàn bộ 601 record parse-valid của Cosmos đều thuộc **MVTec-AD** — đúng nguồn dễ nhất trong 4 nguồn của MMAD.

So sánh	Cosmos 3 Nano	Qwen2-VL-2B	Kết quả
❌ Sai — Cosmos (MVTec-AD) vs Qwen (cả 4 nguồn)	73.16%	64.73%	"Cosmos hơn 8.4 điểm"
✅ Đúng — cả hai trên MVTEC-AD	73.16%	75.25%	Qwen hơn 2.1 điểm

Bảng đặt 73.16% cạnh 64.73% là **so sánh không hợp lệ** và đảo ngược kết luận. Chênh giữa nguồn dễ nhất (MVTec-AD 75.25%) và khó nhất (MVTec-LOCO 55.22%) lên tới 20 điểm.

2. Cả hai VLM đều thất bại đúng ở chỗ quan trọng nhất

Trên subtask **Anomaly Detection** — sát nhất với bài toán B3 của công ty — cả hai đều **thua baseline ngu**:

Model	Recall	F1	Baseline F1	Miss rate
Qwen2-VL-2B	0.481	0.584	0.756	51.9%
Cosmos 3 Nano	0.143	0.250	0.830	85.7%

Cả hai đều thiên lệch mạnh về phía "không có lỗi". Accuracy tổng che mất điều này — đúng lý do template cấm dùng accuracy làm metric chính cho dữ liệu mất cân bằng.

3. Kết quả 100% của V-JEPA 2 chưa được phép công bố như một thành tựu

Ablation 14 frame cũng cho 100% (gap 0.0), cosine test→train 0.9922, và static-frame control **chưa chạy**. Điều chứng minh được chỉ là: 7 công đoạn HATREC **tách tuyến tính được** trong không gian embedding của V-JEPA 2.

Còn thiếu — chưa có báo cáo

Model × Dataset	Trạng thái	Ghi chú
Cosmos3-Nano × PIADE/ALPI (B0 + B5)	❌ 0%	Đầu việc bắt buộc, ưu tiên cao nhất theo handoff §12. Chưa có dữ liệu, script hay thư mục nào trong workspace
Qwen2-VL-2B × HATREC	❌ Không có dữ liệu trên máy	Con số 15.02% trong bảng team là của người khác
Cosmos3-Nano × MMAD — 3 nguồn còn lại	❌ Chưa chạy	GoodsAD, VisA, MVTEC-LOCO đều n = 0

Việc bắt buộc phải bổ sung cho các báo cáo đã có

Xếp theo tỉ lệ giá trị/chi phí:

1. **Static-frame control cho cả hai báo cáo HATREC** (03, 04) — rõ, nhanh, quyết định hiệu lực của cả hai. Với V-JEPA đây là điều kiện tiên quyết để con số 100% có ý nghĩa.
 2. **Chạy 100 câu MMAD giống hệt nhau trên cả hai backend Cosmos** — để giải thích chênh lệch 73.16% vs 49.77%. Chưa hiểu nguyên nhân thì mọi record gộp về sau đều mang lỗi hệ thống.
 3. **Blind-image control trên ~500 câu MMAD** — cho cả Qwen và Cosmos, xác nhận model thật sự dùng ảnh.
 4. **Mở rộng Cosmos sang MVTec-LOCO** — nguồn khó nhất, cho cận dưới thực tế.
 5. **Lưu probability outputs** ở mọi lần chạy sau — hiện chưa report được ECE/abstention cho hai model MMAD.
 6. **Temporal shuffle control** cho HATREC.
-

Ghi chú về quy trình

- Mọi baseline trong các báo cáo này được **tính lại bằng code trên đúng tập record mà model đã trả lời**, không mượn từ nguồn khác và không lấy từ paper.
- Metric chính là **Macro-F1** ở mọi nơi dữ liệu mất cân bằng; accuracy chỉ báo kèm khi đó là protocol công bố của dataset (MMAD).
- Theo lưu ý chung của team: **chờ khung codebase chung từ Quỳnh Anh** trước khi viết code cho các lần chạy tiếp theo, để định dạng kết quả thống nhất và gộp được. Bốn báo cáo này viết từ dữ liệu **đã thu thập xong**, không phát sinh code chạy model mới.
- Chi phí đến thời điểm này: **0 đ** — toàn bộ chạy trên Kaggle free tier và NVIDIA Build free tier, không thuê server.

Report — Qwen2-VL-2B × MMAD

Mục 1: Thông tin cơ bản

Mục	Nội dung
Tên model test	Qwen2-VL-2B-Instruct (Qwen/Qwen2-VL-2B-Instruct)
Dataset test trên	MMAD (ICLR 2025) — industrial visual anomaly benchmark
Quy mô	39,670 câu MCQ / 8,366 ảnh / 38 category / 4 nguồn / 7 task
Ngày test	2026-07-29 → 2026-07-30
Người test	Sơn
Manifest SHA-256	ff6bf9547135bb9b58dcafcfbaf73e0cfbf804edea0b6dee57fa4dbbf5fb5d6

Mục 2: Setup

Mục	Nội dung
Chạy ở đâu	Kaggle, GPU T4 (free tier)
Chi phí	0 đ — không thuê server
Bản model	Qwen2-VL-2B-Instruct, 2B params
Backend	Transformers FP16, attention SDPA, batch = 4, có OOM fallback
Zero-shot?	CÓ — hoàn toàn zero-shot. Không fine-tune, không probe, không few-shot example nào trong prompt
Có train gì không?	KHÔNG. Không XGBoost, không linear probe, không head nào được huấn luyện
Sinh output	Deterministic (greedy). Parser chỉ chấp nhận đúng một chữ cái A–D không nhập nhầm
Notebook	research/mmad_model_benchmark/models/qwen2_vl/Qwen2VL_2B_MMAD_Full.ipynb
Resume	Checkpoint JSONL theo <code>sample_id</code> ổn định, không dùng vị trí

Ghi chú: đây là setting zero-shot theo protocol nội bộ, **không phải** bản tái hiện setting 1-shot và domain-knowledge của paper MMAD gốc. Vì vậy không so trực tiếp được với leaderboard chính thức.

Mục 3: Kiểm tra leak

Vì đây là zero-shot thuần, **không tồn tại tập train của mình** → không có khái niệm cycle/participant trùng giữa train/test, và embedding-similarity train↔test không áp dụng. Các kiểm tra thay thế đã làm:

Kiểm tra	Kết quả	Trạng thái
Tên file query có lỗi nhãn không	Đổi hết thành <code>sample_XXXX</code> trước khi đưa vào prompt	✅ PASS
Nhãn source / class / defect có xuất hiện trong prompt không	Không — chỉ có ảnh + câu hỏi + 4 lựa chọn	✅ PASS
Annotation gốc có bị chèn vào prompt không	Không — chỉ dùng để chấm điểm	✅ PASS
Parser có "đoán hột" model không	Không — chỉ nhận A–D rõ ràng, còn lại tính <code>parse_failure</code>	✅ PASS
Model có thấy MMAD lúc pretrain không	CHƯA KIỂM TRA ĐƯỢC	⚠️ REVIEW

Kết luận: Ở mức protocol, dữ liệu đủ độc lập — model không nhận được manh mối nào ngoài pixel và câu hỏi. Rủi ro còn lại là **nhiểm bẩn từ pretraining**: MMAD là dataset public trên HuggingFace từ ICLR 2025, Qwen2-VL có thể đã gặp ảnh MVTec-AD/VisA trong dữ liệu huấn luyện. Không có cách kiểm chứng từ phía mình. Rủi ro này áp dụng như nhau cho mọi model open-source được so sánh, nên **không làm sai lệch phép so sánh giữa các model**, chỉ làm con số tuyệt đối lạc quan hơn thực tế.

Mục 4: Kết quả chính

4.1 Toàn bộ MMAD

MMAD là MCQ 2–4 lựa chọn, phân bố đáp án hơi lệch (A 30.4% / B 30.1% / C 20.3% / D 19.2%). Metric chính báo cáo là **Macro-F1 trên nhãn đáp án** kèm micro accuracy theo protocol công bố của MMAD.

	Micro accuracy	Macro-F1	n
Qwen2-VL-2B	64.73% (CI 95% 64.26–65.20)	0.6499	39,669
Baseline majority-letter (luôn trả lời A)	30.38%	0.1165	39,669
Baseline random-choice (kỳ vọng)	30.21%	—	39,669
Chênh lệch vs majority	+34.35 điểm (gấp 2.13×)	+0.5334	

Baseline được tính bằng code riêng trên **đúng 39,669 record model đã trả lời**, không mượn từ nguồn khác.

4.2 Theo nguồn dữ liệu

Nguồn	n	Accuracy	CI 95%
MVTec-AD	8,336	75.25%	74.31–76.17
GoodsAD	13,088	64.23%	63.40–65.04
VisA	10,621	63.93%	63.01–64.84
MVTec-LOCO	7,624	55.22%	54.10–56.33

Chênh 20 điểm giữa nguồn dễ nhất và khó nhất. **Hệ quả quan trọng cho việc so sánh:** bất kỳ model nào chỉ chạy trên MVTec-AD sẽ có con số cao giả tạo. Xem `02_cosmos3_nano_mmad.md`.

4.3 Theo task

Task	n	Accuracy
Object Classification	3,155	93.82%
Object Analysis	9,160	78.30%
Defect Analysis	4,782	72.90%
Defect Description	4,710	63.74%
Anomaly Detection	8,297	58.31%
Defect Localization	4,877	46.73%
Defect Classification	4,688	41.42%

4.4 Anomaly Detection — subtask quan trọng nhất về mặt vận hành

Đây là dữ liệu mất cân bằng (60.83% câu là "có lỗi"), nên **không dùng accuracy**:

	Precision	Recall	F1	Miss rate	Overkill rate
Qwen2-VL-2B	0.7428	0.4807	0.5837	51.93%	25.85%
Baseline "luôn nói có lỗi"	0.6083	1.0000	0.7564	0%	100%
Chênh lệch	+0.1345	-0.5193	-0.1727		

 **Trên riêng subtask Anomaly Detection, Qwen2-VL-2B THUA baseline ngu.** F1 0.584 so với 0.756; accuracy 58.31% so với 60.83%. Model bỏ sót hơn một nửa số ca lỗi thật.

Chi tiết theo nguồn (mức bỏ sót rất khác nhau):

Nguồn	Precision	Recall	F1	Miss rate
MVTec-AD	0.850	0.834	0.841	16.6%
VisA	0.650	0.689	0.669	31.1%
GoodsAD	0.733	0.254	0.377	74.6%
MVTec-LOCO	0.722	0.167	0.272	83.3%

4.5 Độ trễ

Median 0.687 s/câu, p95 0.773 s, mean 0.691 s. Toàn bộ 39,670 câu chạy trong khoảng 7.6 giờ GPU T4.

Mục 5: Kiểm tra shortcut

MMAD là **ảnh tĩnh đơn**, không phải video → **test static-frame không áp dụng**.

Phép kiểm tương đương cho ảnh tĩnh là **blind-image control** (thay ảnh thật bằng ảnh nhiễu hoặc ảnh không liên quan, giữ nguyên câu hỏi). Nếu điểm không giảm → model đang trả lời bằng kiến thức ngôn ngữ chứ không nhìn ảnh.

Kiểm tra	Trạng thái
Blind-image control	✗ CHƯA LÀM
Answer-position bias	✓ Đã đo

Answer-position bias đã đo được:

Đáp án	Tỉ lệ trong ground truth	Tỉ lệ model chọn	Lệch
A	30.38%	31.10%	+0.72%
B	30.11%	27.02%	-3.09%
C	20.31%	19.57%	-0.74%
D	19.20%	22.30%	+3.10%

Lệch tối đa 3.1 điểm — có thiên lệch vị trí nhẹ nghiêng về D, nhưng chưa đủ lớn để giải thích kết quả. Không phải shortcut nghiêm trọng.

Kết luận mục 5: chưa đủ căn cứ khẳng định model thật sự "nhìn" ảnh. Blind-image control là việc bắt buộc phải bổ sung — với model 2B và độ chênh giữa các task rất lớn (93.8% vs 41.4%), khả năng một phần điểm đến từ prior ngôn ngữ là có thật.

Mục 6: Ví dụ lỗi cụ thể

Toàn bộ lấy từ tập test đầy đủ (không có tập train). Mỗi ca ghi rõ model đoán gì / đáp án thật / phân loại nguyên nhân.

Lỗi 1 — `mmad_full_00064` (MVTec-AD / bottle / Anomaly Detection)

- Câu hỏi:** "Is there any defect in the object?" — A) No. B) Yes.
- Đáp án thật:** A — "No." (ảnh này là hàng bình thường)
- Model đoán:** B — "Yes."
- Loại lỗi: Lý do khác — thiên lệch trả lời.** Model báo động giả trên hàng tốt. Khớp với overkill_rate 25.85% toàn cục. Ca `mmad_full_00065` cùng category lặp lại y hệt.

Lỗi 2 — `mmad_full_08311` (MVTec-AD / bottle / Defect Classification)

- Câu hỏi:** "What is the type of the defect?" — A) Breakage. B) Stain. C) Discoloration. D) Crack.
- Đáp án thật:** A — "Breakage."
- Model đoán:** D — "Crack."
- Loại lỗi: Nhầm lẫn giữa 2 nhãn quá giống nhau.** "Breakage" (vỡ hẵn) và "Crack" (nứt) khác nhau ở mức độ, đòi hỏi phân biệt độ sâu/mức phá huỷ. Đây là mẫu lỗi chi phối task Defect Classification (41.42% — task yếu nhất).

Lỗi 3 — `mmad_full_12991` (MVTec-AD / bottle / Defect Localization)

- Câu hỏi:** "Where is the defect?" — A) Bottom center. B) Left side. C) Right side. D) Top center.
- Đáp án thật:** A — "Bottom center of the image."
- Model đoán:** D — "Top center of the image."

- Loại lỗi: Lý do khác — yếu định vị không gian. Model chọn đúng trục (center) nhưng ngược chiều dọc hoàn toàn. Đây không phải nhầm lẫn nhãn giống nhau mà là hỏng khả năng grounding toạ độ — đúng với Defect Localization 46.73%.

Lỗi 4 — `mmad_full_30520` (MVTec-AD / bottle / Object Analysis)

- Câu hỏi: "Where is the location of the object's opening?" — A) Bottom. B) Side. C) Top. D) Closed.
- Đáp án thật: C — "At the top of the object."
- Model đoán: A — "At the bottom of the object."
- Loại lỗi: Lý do khác — yếu định vị không gian. Cùng dạng lỗi trên/dưới với Lỗi 3, nhưng ở câu hỏi về vật thể bình thường chứ không phải về lỗi. Xác nhận đây là điểm yếu hệ thống của model, không phải do defect khó nhìn.

Lỗi 5 — `mmad_full_27502` (MVTec-AD / grid / Object Classification)

- Câu hỏi: "What kind of product is in the image?" — A) Wallpaper. B) Plastic sheeting. C) Ceramic tile. D) Textured fabric.
- Đáp án thật: D — "Textured fabric."
- Model đoán: B — "Plastic sheeting."
- Loại lỗi: Nhiều/mất chi tiết do xử lý. Phân biệt vải dệt với tấm nhựa phụ thuộc vào kết cấu sợi ở tần số không gian cao — thứ dễ mất nhất khi resize ảnh về độ phân giải đầu vào của model.

Lỗi 6 — `mmad_full_22618` (MVTec-AD / bottle / Defect Analysis)

- Câu hỏi: "What may be the effect of the defect?" — A) Change in liquid flavor or contamination. B) Unsellable. C) Affect ability to hold liquid. D) Leaking contents.
- Đáp án thật: A — "It could cause a change in liquid flavor or contamination."
- Model đoán: D — "It could lead to leaking contents."
- Loại lỗi: Nhầm lẫn giữa 2 nhãn quá giống nhau. Cả 4 lựa chọn đều là hệ quả hợp lý của một chai bị lỗi; muốn chọn đúng phải biết loại lỗi cụ thể trên ảnh. Model suy luận hệ quả chung chung thay vì căn cứ vào bằng chứng thị giác.

Phân bố lỗi theo category (Pareto — 5 category chiếm 32.3% tổng lỗi)

Nguồn	Category	Số lỗi	% tổng lỗi
GoodsAD	drink_bottle	1,248	8.92%
GoodsAD	food_bottle	876	6.26%
GoodsAD	food_package	824	5.89%
MVTec-LOCO	screw_bag	814	5.82%
MVTec-LOCO	juice_bottle	758	5.42%

Mục 7: Kết luận cuối cùng

Dataset: MMAD (toàn bộ 39,670 câu)

- ☒ **Model này THẮNG RÕ RÀNG so với baseline đơn giản** — 64.73% vs 30.38% majority-letter, chênh +34.35 điểm, khoảng tin cậy không chồng lấn.
- ☐ Model này NGANG BẰNG baseline đơn giản
- ☐ Model này THUA baseline đơn giản

Kết luận phụ bắt buộc phải ghi kèm — subtask Anomaly Detection (n = 8,297):

- ☐ THẮNG RÕ RÀNG
- ☐ NGANG BẰNG
- ☒ **THUA baseline đơn giản** — F1 0.584 vs 0.756 của baseline "luôn nói có lỗi"; miss rate 51.93%.

Hai kết luận này không mâu thuẫn: Qwen2-VL-2B là **model mô tả và nhận dạng vật thể tốt**, nhưng **không dùng được làm công phát hiện bất thường** vì bỏ sót quá nửa số ca lỗi. Nếu mục tiêu công ty là B3 (anomaly & fault localization), con số 64.73% không phản ánh đúng năng lực thực tế.

Mục 8: Lưu ý / giới hạn

Mẫu test có đủ lớn không?

Có. 39,669 record parse-valid, CI 95% chỉ ± 0.47 điểm. Đây là bộ đầy đủ, không phải subset. Mọi kết luận ở mức toàn dataset đều vững về mặt thống kê.

Có phát hiện leak không? Kết quả Mục 4 có đáng tin?

Không phát hiện leak ở mức protocol — tên file đã trung tính, nhãn không lọt vào prompt, parser không đoán hộ. Kết quả Mục 4 đáng tin ở mức so sánh tương đối giữa các model chạy cùng manifest. Con số tuyệt đối có thể lạc quan do khả năng nhiễm bẩn pretraining, không kiểm chứng được.

Có điều gì chưa kiểm tra mà làm thêm sẽ chắc chắn hơn?

1. **Blind-image control** — bắt buộc. Không có nó thì chưa chứng minh được model thật sự dùng ảnh. Chi phí thấp: chạy lại một mẫu ~500 câu với ảnh bị xáo trộn.
 2. **Chưa lưu probability/logits** — nên không claim được gì về calibration (ECE) hay khả năng abstain. Cần bật ở lần chạy sau, đây là yêu cầu của Cosmos-style confidence.
 3. **Chưa chạy setting 1-shot và domain-knowledge** của MMAD gốc → không đối chiếu được với leaderboard chính thức và với mốc GPT-4o ~74.9%.
 4. **Chưa phân tích ảnh hưởng độ phân giải** — nghi ngờ ở Lỗi 5 (mất kết cấu do resize) chưa được kiểm chứng bằng thí nghiệm đổi độ phân giải đầu vào.
 5. **Chưa có human baseline nội bộ** trên cùng subset để biết trần thực tế của bộ dữ liệu này.
-

Nguồn dữ liệu và mã nguồn

Loại	Đường dẫn
Prediction thô	research/mmad_model_benchmark/models/qwen2_vl/qwen2_vl_mmad_full_results/predictions.jsonl
Bảng chấm điểm	.../qwen2_vl_mmad_full_results/predictions_scored.csv
Metrics	.../qwen2_vl_mmad_full_results/metrics.json
Phân tích sâu + hình	.../qwen2_vl_mmad_full_results/deep_analysis/
Hình tổng quan	.../qwen2_vl_mmad_full_results/full_mmad_analysis.png
Notebook	research/mmad_model_benchmark/models/qwen2_vl/Qwen2VL_2B_MMAD_Full.ipynb
Repo public	https://github.com/ahsown/mini-world-model

Hình nên gắn kèm khi trình bày:

deep_analysis/02_task_source_accuracy_ci.png , deep_analysis/05_anomaly_by_source.png , deep_analysis/07_error_pareto_latency.png .

Report — Cosmos 3 Nano Reasoner × MMAD

⚠ Cảnh báo đọc trước: báo cáo này dựa trên **622/39,670 câu (1.57%)**, chạy trên **hai backend khác nhau** với **hai bộ trọng số khác nhau**, và **100% câu đã chạy đều thuộc một nguồn duy nhất (MVTec-AD)**. Không được dùng con số ở đây như một điểm leaderboard của Cosmos 3.

Mục 1: Thông tin cơ bản

Mục	Nội dung
Tên model test	Cosmos 3 Nano Reasoner (NVIDIA)
Dataset test trên	MMAD (ICLR 2025)
Độ phủ đã chạy	622 record / 39,670 câu = 1.57%
Ngày test	2026-07-29 → 2026-07-31
Người test	Sơn
Manifest SHA-256	ff6bf9547135bb9b58dcafcfbafb73e0cfbf804edea0b6dee57fa4dbbf5fb5d6 (giống hệt bản Qwen2-VL)

Mục 2: Setup

Chạy trên **hai backend riêng biệt**. Đây là điểm quan trọng nhất của báo cáo — hai backend cho ra kết quả khác nhau rất xa nên phải tách bạch.

Backend A — NVIDIA Build UI (endpoint chính thức)

Mục	Nội dung
Chạy ở đâu	Máy local, điều khiển trình duyệt tự động tới NVIDIA Build
Chi phí	0 đ (free tier của NVIDIA Build)
Bản model	Cosmos 3 Nano Reasoner, endpoint chính thức, không lượng tử hoá
Số record	229 (221 parse-valid)
Latency trung bình	21.0 s/câu (median 8.2 s)
Giới hạn	Mỗi request chỉ nhận 1 ảnh → bắt buộc zero-shot, không làm được 1-shot

Backend B — Kaggle T4×2 (checkpoint cộng đồng)

Mục	Nội dung
Chạy ở đâu	Kaggle, GPU T4×2 (free tier)
Chi phí	0 đ
Bản model	ThePyProgrammer/Cosmos3-Nano-reasoner-bnb8-vllm-und-only — checkpoint cộng đồng, lượng tử hoá BNB8
Nạp bằng	Qwen3VLForConditionalGeneration — vì checkpoint Cosmos khai báo kiến trúc tương thích Qwen3-VL. Trọng số vẫn là của Cosmos; KHÔNG phải thay bằng Qwen
Số record	393 (380 parse-valid)
Latency trung bình	54.7 s/câu (median 48.0 s, p95 113.4 s)
Ngân sách chạy	6.0 giờ → chỉ được 393 câu

Nhãn báo cáo bắt buộc dùng cho Backend B:

Cosmos 3 Nano Reasoner, community BNB8 quantized checkpoint, zero-shot inference on Kaggle T4×2.

Mục chung	Nội dung
Zero-shot?	CÓ — hoàn toàn zero-shot trên cả hai backend
Có train gì không?	KHÔNG . Không fine-tune, không probe, không head huấn luyện
Prompt / parser / evaluator	Giống hệt bản Qwen2-VL — cùng manifest hash, cùng system prompt, cùng parser

⚠ Hai backend không so sánh trực tiếp được với nhau: khác precision (FP gốc vs BNB8), khác runtime, khác cách sinh output. Việc gộp 622 record thành một con số duy nhất đã được đánh dấu trong `metrics_combined.json` là *"mixed-backend operational merge; not a single-model leaderboard score"*.

Mục 3: Kiểm tra leak

Giống bản Qwen2-VL: zero-shot thuần → không có tập train của mình, nên không xét cycle/participant trùng lặp hay embedding similarity train↔test.

Kiểm tra	Kết quả	Trạng thái
Cùng manifest hash với model đối chứng	<code>ff6bf954...</code> khớp tuyệt đối	✅ PASS
Tên file query có lộ nhãn không	Đổi thành <code>sample_XXXX</code>	✅ PASS
Nhãn source/class/defect trong prompt	Không có	✅ PASS
Parser có ưu ái model nào không	Cùng một parser cho cả hai model	✅ PASS
Nhiệm bản pretraining	Chưa kiểm chứng được	⚠ REVIEW
Thiên lệch độ phủ (coverage bias)	601/601 record parse-valid đều là MVTec-AD	❌ FAIL

Kết luận: không có leak theo nghĩa cổ điển, nhưng có một vấn đề **ngghiêm trọng hơn leak** về mặt hiệu lực kết quả — **thiên lệch chọn mẫu**. Cả 601 câu đã chạy đều thuộc MVTec-AD, mà theo kết quả Qwen2-VL trên bộ đầy đủ thì MVTec-AD chính là **nguồn dễ nhất** (75.25%, cao hơn MVTec-LOCO 20 điểm). Mọi con số dưới đây vì thế **lạc quan có hệ thống**, và không được dùng để so với các model đã chạy đủ 4 nguồn.

Mục 4: Kết quả chính

4.1 Theo từng backend — kèm baseline tính trên CÙNG tập record

Baseline majority-letter được tính riêng cho từng segment, trên đúng các record mà segment đó đã trả lời.

Cấu hình	n	Micro accuracy	Macro-F1	Baseline majority	Chênh lệch
Kaggle T4×2 (BNB8)	380	73.16%	0.7460	35.53%	+37.63 điểm
NVIDIA Build UI (chính thức)	221	49.77%	0.4957	51.13%	-1.36 điểm
Gộp cả hai (chỉ tham khảo)	601	64.56%	0.7024	41.26%	+23.30 điểm

Trên endpoint chính thức của NVIDIA, Cosmos 3 Nano THUA baseline ngu — 49.77% so với 51.13% của việc luôn trả lời một chữ cái cố định.

Baseline random-choice (kỳ vọng, tính theo số lựa chọn thực của từng câu): 37.48% cho tập gộp.

Khoảng tin cậy 95% của hai segment **không chồng lấn**:

- Kaggle T4×2: 68.49% – 77.37%
- NVIDIA Build UI: 43.24% – 56.31%

Đây không phải nhiễu thống kê. Hai backend đang hành xử như hai model khác nhau.

4.2 So sánh với Qwen2-VL-2B — bắt buộc khớp nguồn

So sánh	Cosmos 3 Nano	Qwen2-VL-2B	Kết luận
Sai — Cosmos (MVTec-AD) vs Qwen (toàn bộ 4 nguồn)	73.16%	64.73%	Cosmos "hơn 8.4 điểm" — so sánh không hợp lệ
Đúng — cả hai trên MVTec-AD	73.16% (Kaggle, n=380)	75.25% (n=8,336)	Qwen hơn 2.1 điểm
Đúng — cả hai trên MVTec-AD, gộp 2 backend	64.56% (n=601)	75.25%	Qwen hơn 10.7 điểm

Đây là điểm sửa quan trọng nhất của báo cáo. Bảng gốc trong `metrics_combined.json` đặt 73.16% cạnh 64.73% khiến Cosmos trông vượt trội; thực tế khi khớp nguồn thì Cosmos **không** vượt Qwen2-VL-2B.

4.3 Theo task (segment Kaggle T4×2, n = 380)

Task	n	Accuracy
Object Classification	23	100.00%
Object Analysis	67	94.03%
Defect Analysis	53	84.91%
Defect Localization	56	82.14%
Defect Description	54	75.93%
Defect Classification	48	60.42%
Anomaly Detection	79	39.24%

4.4 Anomaly Detection — dữ liệu mất cân bằng, không dùng accuracy

Trong 79 câu AD của segment Kaggle, 56 câu (70.89%) có nhãn "có lỗi".

	Precision	Recall	F1	Miss rate	Overkill
Cosmos 3 Nano (BNB8)	1.0000	0.1429	0.2500	85.71%	0.00%
Baseline "luôn nói có lỗi"	0.7089	1.0000	0.8295	0%	100%
Chênh lệch	+0.2911	-0.8571	-0.5795		

✖

THUA baseline rất nặng. Cosmos đúng tuyệt đối khi nó dám khẳng định có lỗi (precision 1.0 — không báo động giả lần nào), nhưng nó **chỉ dám khẳng định 8/56 lần**. 48/56 ca lỗi thật bị bỏ qua.

Đây là hành vi "luôn nói không có lỗi" — an toàn cho chỉ số precision nhưng **vô dụng cho một cổng kiểm tra chất lượng công nghiệp**.

4.5 Tỷ lệ hoàn thành và độ trễ

	Kaggle T4×2	NVIDIA Build UI
Record thử	393	229
Parse-valid	380 (96.7%)	221 (96.5%)
Parse failure	13 (3.31%)	8
Latency mean	54.7 s	21.0 s
Latency median	48.0 s	8.2 s
Completion rate so với 39,670 câu	0.996%	0.58%

Với 54.7 s/câu, chạy hết phần còn lại cần **≈ 600 giờ GPU**. Đây là lý do cơ chế shared checkpoint qua GitHub được xây (đã code xong, chưa seed shard nào).

Mục 5: Kiểm tra shortcut

MMAD là ảnh tĩnh đơn → **test static-frame không áp dụng**.

Kiểm tra	Trạng thái
Blind-image control (thay ảnh, giữ câu hỏi)	✗ CHƯA LÀM
Answer-position bias	✗ CHƯA ĐO (mẫu 601 quá nhỏ để đo tin cậy)

Có một quan sát gián tiếp đáng chú ý từ Mục 6: reasoning của Cosmos trên endpoint chính thức **mô tả ảnh khá chi tiết và chính xác** (màu, hình, bề mặt, ánh sáng) rồi mới kết luận sai. Điều này gợi ý model **có nhìn ảnh** — lỗi nằm ở bước phán đoán bất thường chứ không phải ở bước tri giác. Nhưng đây là quan sát định tính, không thay thế được blind-image control.

Mục 6: Ví dụ lỗi cụ thể

Ưu điểm của Cosmos so với Qwen: nó xuất ra chuỗi suy luận `<think>...</think>` nên truy được nguyên nhân sai.

Lỗi 1 — `mmad_full_00004` (MVTec-AD / bottle / Anomaly Detection / NVIDIA Build UI)

- Câu hỏi:** "Is there any defect in the object?" — A) Yes. B) No.
- Đáp án thật:** A — "Yes." (ảnh có lỗi)
- Model đoán:** B — "No."
- Suy luận của model:** "...the object has a smooth, polished surface with subtle reflections and highlights. It's uniformly black with no visible scratches, dents, or irregularities..."
- Loại lỗi: Thiếu thông tin đầu vào / mất chi tiết do xử lý.** Model mô tả bề mặt đúng nhưng khẳng định "không có bất thường nào nhìn thấy được" — lỗi trên MVTec-AD bottle thường rất nhỏ, có khả năng đã bị mất khi ảnh qua pipeline nén/resize của UI.

Lỗi 2 — `mmad_full_00008` (MVTec-AD / bottle / Anomaly Detection / NVIDIA Build UI)

- Đáp án thật:** A — "Yes." | **Model đoán:** B — "No."
- Suy luận của model:** "...the edges are slightly blurred, which might be due to the camera's depth of fi[eld]..."
- Loại lỗi: Model hallucinate — bịa lý do để bỏ qua bằng chứng.** Model có thấy điểm bất thường (cạnh mờ) nhưng tự nghĩ ra một lời giải thích lành tính ("do độ sâu trường ảnh") rồi loại nó khỏi kết luận. Đây là dạng lỗi nguy hiểm nhất trong kiểm tra chất lượng: model hợp lý hoá khuyết tật thành hiện tượng quang học.

Lỗi 3 — `mmad_full_00021` (MVTec-AD / bottle / Anomaly Detection / NVIDIA Build UI)

- Câu hỏi:** A) No. B) Yes. (thứ tự đảo so với Lỗi 1)
- Đáp án thật:** B — "Yes." | **Model đoán:** A — "No."
- Suy luận:** "...the object has concentric ridges... metallic sheen... slight reflective highlight on one side..."
- Loại lỗi: Lý do khác — thiên lệch hệ thống về phía "không có lỗi".** Ba ca liên tiếp đều sai theo cùng một chiều, kể cả khi thứ tự đáp án bị đảo → không phải thiên lệch vị trí, mà là thiên lệch nội dung. Khớp với miss rate 85.71%.

Lỗi 4 — `mmad_full_08429` (MVTec-AD / cable / Defect Classification / Kaggle T4x2)

- Câu hỏi:** "What is the type of the defect?" — A) Poke insulation. B) Fraying. C) Abrasion. D) Discoloration.

- **Đáp án thật:** A — "Poke insulation." | **Model đoán:** C — "Abrasion."
- **Suy luận:** model liệt kê đúng định nghĩa từng loại ("*Poke insulation usually refers to the insulation being punctured... Fraying would be...*") rồi vẫn chọn sai.
- **Loại lỗi: Nhầm lẫn giữa 2 nhãn quá giống nhau.** Model nắm đúng khái niệm nhưng không ánh xạ được vào bằng chứng thị giác cụ thể — kiến thức có, grounding thiếu.

Lỗi 5 — `mmad_full_08433` (MVTec-AD / capsule / Defect Classification / Kaggle T4×2)

- **Câu hỏi:** A) Crack. B) Leakage. C) Discoloration. D) Dent.
- **Đáp án thật:** A — "Crack." | **Model đoán:** C — "Discoloration."
- **Suy luận:** "*...the orange section has a slight discoloration or uneven texture. Also, there's a sma[ll]...*" — model nhận ra cả hai manh mối nhưng chọn manh mối nổi bật hơn về màu sắc.
- **Loại lỗi: Lý do khác — chọn tín hiệu nổi bật thay vì tín hiệu đúng.** Vết nứt nhỏ khó thấy hơn vùng đổi màu, model bám vào cái dễ thấy.

Tổng hợp phân bố lỗi (601 record parse-valid, 213 sai)

Task	Số lỗi	% tổng lỗi
Anomaly Detection	159	74.6%
Defect Classification	19	8.9%
Defect Description	13	6.1%
Defect Localization	10	4.7%
Defect Analysis	8	3.8%
Object Analysis	4	1.9%

Gần 3/4 toàn bộ lỗi tập trung vào đúng một task — Anomaly Detection. Theo backend: NVIDIA Build UI 111 lỗi / Kaggle T4×2 102 lỗi.

Mục 7: Kết luận cuối cùng

Vì hai backend chạy hai bộ trọng số khác nhau và cho kết quả có khoảng tin cậy không chồng lấn, **một kết luận chung ở mức dataset là không bảo vệ được.** Ghi riêng theo từng cấu hình:

Cosmos 3 Nano — BNB8 cộng đồng, Kaggle T4×2 — trên MMAD (subset MVTec-AD, n = 380)

- ☒ **THẮNG RÕ RÀNG** so với baseline đơn giản — 73.16% vs 35.53%
- ☐ NGANG BẰNG
- ☐ THUA

Cosmos 3 Nano — endpoint chính thức NVIDIA Build — trên MMAD (subset MVTec-AD, n = 221)

- ☐ THẮNG RÕ RÀNG
- ☐ NGANG BẰNG
- ☒ **THUA** baseline đơn giản — 49.77% vs 51.13%

Kết luận phụ — subtask Anomaly Detection (n = 79, segment Kaggle)

- ☒ **THUA** baseline đơn giản — F1 0.250 vs 0.830

Kết luận so với Qwen2-VL-2B (khớp nguồn MVTec-AD): Cosmos 3 Nano **chưa vượt** Qwen2-VL-2B — 73.16% (bản BNB8, cấu hình tốt nhất) so với 75.25%. Trong khi đó Cosmos chậm hơn **79x** (54.7 s vs 0.69 s mỗi câu).

Mục 8: Lưu ý / giới hạn

Mẫu test có đủ lớn không?

KHÔNG. $622/39,670 = 1.57\%$. Nghiêm trọng hơn: 601/601 record parse-valid đều thuộc **một nguồn duy nhất** (MVTec-AD), không có câu nào của GoodsAD, VisA hay MVTec-LOCO. Một số subtask chỉ có 23 câu (Object Classification). Đây chưa đủ để kết luận về năng lực của Cosmos 3 trên MMAD.

Có phát hiện leak không? Kết quả Mục 4 có đáng tin?

Không có leak protocol. Nhưng có **thiên lệch độ phủ nghiêm trọng** làm kết quả lạc quan có hệ thống — MVTec-AD là nguồn dễ nhất (theo Qwen: 75.25% vs 55.22% của MVTec-LOCO). Nếu chạy đủ 4 nguồn, con số 73.16% gần như chắc chắn sẽ giảm. Vì vậy Mục 4 **chỉ đáng tin trong phạm vi MVTec-AD**, và mọi so sánh liên model bắt buộc phải khớp nguồn.

Có điều gì chưa kiểm tra mà làm thêm sẽ chắc chắn hơn?

1. **Giải thích chênh lệch 73.16% vs 49.77% giữa hai backend** — đây là việc cấp bách nhất. Cho tới khi hiểu nguyên nhân (lượng tử hoá BNB8? khác nhau ở xử lý ảnh phía UI? khác prompt template?), mọi record gộp về sau đều mang lỗi hệ thống này. Cách kiểm: chạy **cùng 100 câu giống hệt nhau** trên cả hai backend rồi so từng câu một.
 2. **Mở rộng sang 3 nguồn còn lại** — ưu tiên MVTec-LOCO (nguồn khó nhất) để có cận dưới thực tế.
 3. **Blind-image control** — chưa làm.
 4. **Chưa lưu probability outputs** → không claim được calibration hay abstention, dù precision 1.0 gợi ý model đang tự abstain ngầm.
 5. **Chưa seed shared checkpoint** — code đã xong (`common/shared_checkpoint.py` , 3 test pass) nhưng thư mục `checkpoints/cosmos3_mmad/` mới chỉ có README + manifest, chưa có shard dữ liệu nào. Đây là nút thắt để chạy tiếp.
 6. **Chưa đối chiếu với GPT-4o ~74.9%** một cách hợp lệ — mốc đó tính trên toàn bộ MMAD, không phải riêng MVTec-AD.
-

Nguồn dữ liệu và mã nguồn

Loại	Đường dẫn
Prediction gộp	<code>research/mmad_model_benchmark/outputs/cosmos3_combined/predictions_combined.jsonl / .csv</code>
Metrics gộp	<code>.../outputs/cosmos3_combined/metrics_combined.json</code>
Phân tích theo segment	<code>.../outputs/cosmos3_combined/analysis_summary.json</code> , <code>analysis_by_segment.csv</code>
Metrics Kaggle T4×2	<code>.../outputs/cosmos3_t4x2/metrics.json</code>
Notebook Kaggle	<code>.../models/cosmos3/Cosmos3_Nano_MMAD_T4x2_UI_Parity.ipynb</code>
Runner NVIDIA Build	<code>.../models/cosmos3/run_nvidia_build.py</code>
Notebook phân tích	<code>.../analysis/cosmos3_mmad_combined_analysis.ipynb</code> (+ bản <code>.html</code>)
Repo public	<code>https://github.com/ahsown/mini-world-model</code>

Report — Cosmos 3 Nano Reasoner × HATREC

Mục 1: Thông tin cơ bản

Mục	Nội dung
Tên model test	Cosmos 3 Nano Reasoner (NVIDIA), qua endpoint chính thức NVIDIA Build
Dataset test trên	HATREC — video lắp ráp công nghiệp, phân loại 7 công đoạn
Quy mô	546 video / 78 cycle / 7 lớp cân bằng (78 video mỗi lớp)
Đặc điểm video	720×1280, 30 fps, dài trung bình 3.46 s (min 1.57 s, max 7.30 s)
Độ phủ đã chạy	546/546 = 100%
Ngày test	2026-07-27 → 2026-07-28
Người test	Sơn

7 nhãn công đoạn: 0 = Assembling the spring · 1 = Placing the white plastic part · 2 = Screwing-1 · 3 = Inflating the valve · 4 = Placing the black plastic part · 5 = Screwing-2 · 6 = Fixing the cable

Mục 2: Setup

Mục	Nội dung
Chạy ở đâu	Máy local, tự động hoá trình duyệt tới NVIDIA Build
Chi phí	0 đ — free tier, không thuê server
Bản model	Cosmos 3 Nano Reasoner, endpoint chính thức, không lượng tử hoá
Zero-shot?	CÓ — hoàn toàn zero-shot. Không fine-tune, không few-shot example
Có train gì không?	KHÔNG. Không probe, không classifier, không head huấn luyện
Đầu vào	Video đầy đủ (không trích frame), upload trực tiếp lên UI
Prompt	Prompt video công nghiệp có cấu trúc, yêu cầu 9 mục bắt buộc, kết thúc bằng <code>MOST LIKELY HATREC TASK + CONFIDENCE AND LIMITATIONS</code>
Runner	<code>research/hatrec_cosmos3/run_ui.py</code>
Latency trung bình	16.49 s/video

Lưu ý về hai lần chấm điểm: lần chấm đầu (`outputs/ui_evaluation.json`) chỉ parse được 135/546 output → accuracy 18.52%. Parser sau đó được cải tiến, phục hồi được **449/546** output → các con số trong báo cáo này lấy từ lần chấm sâu (`outputs/analysis/deep_audit_summary.json`). Con số 18.52% từng lưu hành **đã lỗi thời**, không dùng nữa.

Mục 3: Kiểm tra leak

Kiểm tra	Kết quả	Trạng thái
Tên file có lộ nhãn không	Tên gốc Cycle_0_task_3.mp4 chứa nhãn. Runner copy sang tên trung tính sample_000123.mp4 trong thư mục tạm rồi mới upload, và verify tên đã upload (upload_verified: true)	PASS
Cycle/participant trùng giữa train/test	Không áp dụng — zero-shot, không có tập train	—
Embedding similarity train↔test	Không áp dụng — model không được huấn luyện trên dữ liệu này	—
Video hỏng / trùng lặp	546/546 video hợp lệ, phân bố lớp cân bằng tuyệt đối (78 mỗi lớp)	PASS
Nhãn có lọt vào prompt không	Không — prompt chỉ mô tả nhiệm vụ và liệt kê 7 lựa chọn	PASS

Kết luận: Với Cosmos 3, **không có đường leak nào**. Model chưa từng thấy HATREC, tên file đã trung tính hoá và được xác minh, nhãn không xuất hiện trong prompt. Dữ liệu đủ độc lập để tin kết quả Mục 4.

⚠ Lưu ý riêng cho dataset: HATREC có các quan ngại về hiệu lực đã phát hiện khi làm việc với V-JEPA 2 (các cycle rất giống nhau về mặt thị giác, similarity 0.99). Điều đó **ảnh hưởng tới model có huấn luyện**, không ảnh hưởng tới đánh giá zero-shot này. Chi tiết ở 04_vjepa2_hatrec.md .

Mục 4: Kết quả chính

Dataset cân bằng hoàn hảo (7 lớp × 78), nên chance = 14.29%. Metric chính: **Macro-F1**.

4.1 Kết quả tổng

	Accuracy	Macro-F1	n
Cosmos 3 Nano — end-to-end (output không parse được tính là sai)	23.63% (CI 20.15–27.29)	0.2162	546
Cosmos 3 Nano — có điều kiện (chỉ tính output parse được)	28.73% (CI 24.72–32.96)	0.2394	449
Baseline majority-class	14.29%	0.0357	546
Baseline random-choice	14.29%	—	546
Chênh lệch (end-to-end vs majority)	+9.34 điểm	+0.1805 (gấp 6.1×)	

Khoảng tin cậy end-to-end [20.15%, 27.29%] **không chứa** mốc baseline 14.29% → chênh lệch có ý nghĩa thống kê.

Cận trên lạc quan nhất (giả sử toàn bộ 97 output không parse được đều đúng): **41.39%**. Kể cả trong kịch bản tốt nhất này, model vẫn sai gần 6/10 lần.

Macro precision 0.2712 · Macro recall 0.2363.

4.2 Theo từng lớp — phát hiện quan trọng nhất

Nhãn	Tên công đoạn	Support	Đúng	Precision	Recall	F1
4	Placing black plastic	78	42	0.326	0.538	0.406
1	Placing white plastic	78	19	0.543	0.244	0.336
2	Screwing-1	78	37	0.236	0.474	0.315
5	Screwing-2	78	22	0.253	0.282	0.267
6	Fixing cable	78	8	0.500	0.103	0.170
0	Assembling the spring	78	1	0.042	0.013	0.020
3	Inflating the valve	78	0	0.000	0.000	0.000

! Sụp đổ lớp (class collapse). Lớp 3 "Inflating the valve" đúng **0/78**, và trong toàn bộ 449 output parse được, model chỉ **một lần duy nhất** dự đoán lớp này. Lớp 0 "Assembling the spring" đúng 1/78.

Phân bố dự đoán (449 output parse được) so với phân bố thật (mỗi lớp phải ~14.3%):

Nhãn dự đoán	Số lần	Tỉ lệ
2 — Screwing-1	157	34.97%
4 — Placing black plastic	129	28.73%
5 — Screwing-2	87	19.38%
1 — Placing white plastic	35	7.80%
0 — Assembling the spring	24	5.35%
6 — Fixing cable	16	3.56%
3 — Inflating the valve	1	0.22%

Model dồn 83% dự đoán vào 3 lớp. Total-variation distance so với phân bố thật = 0.402.

4.3 Độ tin cậy — không hiệu chỉnh

Chỉ số	Giá trị	Ý nghĩa
ECE	0.5552	Sai lệch hiệu chỉnh cực lớn
Brier score	0.5188	
Confidence hay gặp nhất	0.9 (167 lần), 0.95 (57 lần)	Model nói "chắc 90%" trong khi đúng 24%

Model **tự tin sai một cách hệ thống**. Đây là điểm đối lập trực tiếp với yêu cầu "calibrated confidence + abstention" mà dự án đặt ra.

4.4 Tỷ lệ hoàn thành — nút thất hạ tầng

Trạng thái	Số lượng	Tỷ lệ
complete (hoàn tất bình thường)	125	22.9%
partial_timeout (bị cắt giữa chừng)	405	74.2%
timeout_no_output (không ra chữ nào)	16	2.9%
Parse được nhận	449	82.2%

Tuân thủ định dạng: đủ 9 mục = 65.93%; có tag bằng chứng = 36.26%.

77% số lần chạy bị timeout ở mức nào đó. Đây vừa là giới hạn của UI, vừa là dấu hiệu model "nghĩ" quá dài cho một video 3.5 giây.

Mục 5: Kiểm tra shortcut

HATREC là video → mục này có áp dụng.

Kiểm tra	Trạng thái	Ghi chú
Static-frame (lấy 1 frame lặp lại)	✗ CHƯA LÀM	Bắt buộc bổ sung
Temporal shuffle / đảo ngược thứ tự frame	✗ CHƯA LÀM	
Che vật thể / can thiệp nền	✗ CHƯA LÀM	

Chưa có số static-frame nên chưa kết luận được theo tiêu chí <5% / >20–30% của template.

Tuy nhiên có một chỉ báo gián tiếp đã đo được từ phân tích ngữ nghĩa nội dung sinh ra:

Chỉ số	Giá trị
Tỷ lệ bằng chứng mang tính thời gian (mean temporal evidence ratio)	0.1764
Tỷ lệ kết luận có được lập luận đỡ	0.8223
Tỷ lệ khẳng định chắc chắn nhưng không có căn cứ	0.6886
Tỷ lệ có nêu giới hạn nhận thức rõ ràng	0.8590

Chỉ **17.6%** bằng chứng model viện dẫn là về chuyển động/trình tự thời gian; hơn 82% là mô tả tĩnh (vật thể, màu sắc, bố cục bàn làm việc). Đây là **dấu hiệu cho thấy model chủ yếu đọc khung hình tĩnh**, phù hợp với việc nó nhầm lẫn nặng giữa Screwing-1 và Screwing-2 — hai công đoạn gần như không phân biệt được nếu không theo dõi trình tự thời gian.

⚠ Lưu ý về diễn giải: các chỉ số này mô tả **văn bản model sinh ra**, không phải hành vi nội tại của model. Muốn kết luận chắc chắn vẫn phải chạy static-frame control.

Mục 6: Ví dụ lỗi cụ thể

Tất cả lấy từ 546 video test (không có tập train).

Lỗi 1 — Cycle_0/Cycle_0_task_3

- **Đáp án thật:** 3 — Inflating the valve
- **Model đoán:** 0 — Assembling the spring
- **Confidence model tự khai:** 0.9 | runtime: thinking_too_long, 16.42 s
- **Loại lỗi: Model hallucinate + sụp đổ lớp.** Model tự tin 90% vào một nhãn hoàn toàn khác. Kết hợp với việc lớp 3 chỉ được dự đoán 1/449 lần trên toàn bộ dataset → model **không có biểu diễn nào cho công đoạn bơm van**, nó thay bằng công đoạn quen thuộc hơn.

Lỗi 2 — Cycle_10/Cycle_10_task_3

- **Đáp án thật:** 3 — Inflating the valve | **Model đoán:** 1 — Placing white plastic
- **Confidence:** 0.6 | runtime: normal (14.29 s — chạy trọn vẹn, không timeout)
- **Loại lỗi: Model hallucinate.** Đây là ca chạy *bình thường*, không bị cắt, model có đủ thời gian và vẫn sai. Chứng minh lỗi ở lớp 3 **không phải do timeout** mà do bản thân năng lực nhận dạng.

Lỗi 3 — Cycle_0/Cycle_0_task_0

- **Đáp án thật:** 0 — Assembling the spring | **Model đoán:** 2 — Screwing-1
- **Confidence:** 0.9
- **Loại lỗi: Nhầm lẫn giữa 2 nhãn quá giống nhau + thiên lệch về lớp trội.** Lắp lò xo và vặn vít đều là thao tác tay nhỏ trên cùng cụm chi tiết. Screwing-1 là nhãn model dự đoán nhiều nhất (34.97%) → model rơi về lớp mặc định khi không chắc.

Lỗi 4 — Cycle_1/Cycle_1_task_6

- **Đáp án thật:** 6 — Fixing cable | **Model đoán:** không có output (0 ký tự)
- **Trạng thái:** timeout_no_output
- **Loại lỗi: Thiếu thông tin đầu ra — giới hạn hạ tầng.** Model không trả lời gì. Trong chấm end-to-end ca này tính là sai. Có 16 ca như vậy.

Lỗi 5 — Cycle_0/Cycle_0_task_5

- **Đáp án thật:** 5 — Screwing-2 | **Model đoán:** bị cắt giữa chừng sau 4,882 ký tự
- **Trạng thái:** partial_timeout
- **Loại lỗi: Thiếu thông tin đầu vào/đầu ra — model "nghĩ" quá dài.** Model viết gần 5,000 ký tự phân tích cho một video 5.9 giây rồi bị cắt trước khi kết luận. Có 405 ca partial_timeout (74.2%).

Lỗi 6 — Cycle_11/Cycle_11_task_0

- **Đáp án thật:** 0 — Assembling the spring | **Model đoán:** 4 — Placing black plastic
- **Confidence:** 0.6
- **Loại lỗi: Nhầm lẫn giữa 2 nhãn quá giống nhau.** Cả hai đều là thao tác đặt/lắp chi tiết nhỏ; phân biệt được phải nhìn *vật thể nào* đang cầm — chi tiết dễ mất ở độ phân giải sau nén.

Ma trận nhầm lẫn — các cặp nhầm nhiều nhất

Thật → Đoán	Số lần
0 (Assembling spring) → 1 (White plastic)	21
5 (Screwing-2) → 1 (White plastic)	16
5 (Screwing-2) → 2 (Screwing-1)	14
2 (Screwing-1) → 1 (White plastic)	13
0 (Assembling spring) → 2 (Screwing-1)	10

Cặp Screwing-2 → Screwing-1 (14 lần) là bằng chứng trực tiếp: hai công đoạn chỉ khác nhau ở **vị trí trong trình tự thời gian**, và model không phân biệt được.

Mục 7: Kết luận cuối cùng

Dataset: HATREC (546 video, phân loại 7 công đoạn)

- ☒ **Model này THẮNG RÕ RÀNG so với baseline đơn giản** — Macro-F1 0.2162 vs 0.0357 (gấp 6.1×); accuracy 23.63% vs 14.29%; CI 95% [20.15%, 27.29%] không chứa mốc baseline.
- ☐ Model này NGANG BẰNG baseline đơn giản
- ☐ Model này THUA baseline đơn giản

⚠️ "Thắng baseline" ở đây KHÔNG có nghĩa là "dùng được". Model sai 76% số lần, hỏng hoàn toàn 2/7 lớp, tự tin 90% khi đoán sai, và 77% số lần chạy bị timeout. Về mặt vận hành đây là **không khả dụng**. Ô đánh dấu ở trên chỉ phản ánh việc model có tín hiệu thị giác thật vượt trên mức đoán mò — không phải khuyến nghị triển khai.

Mục 8: Lưu ý / giới hạn

Mẫu test có đủ lớn không?

Có, ở mức tổng: 546 video, phủ 100% dataset, các lớp cân bằng tuyệt đối. Ở mức từng lớp thì 78 mẫu/lớp là chấp nhận được nhưng khoảng tin cậy per-class khá rộng. Điểm yếu thật sự không phải cỡ mẫu mà là **chỉ 82.2% output parse được**.

Có phát hiện leak không? Kết quả Mục 4 có đáng tin?

Không phát hiện leak. Tên file đã trung tính hoá và verify, nhãn không lọt vào prompt, model chưa từng huấn luyện trên HATREC. Kết quả Mục 4 **đáng tin** trong phạm vi đã đo. Cảnh báo duy nhất: 17.8% output không parse được có thể không phân bố ngẫu nhiên (lớp 5 Screwing-2 có tới 6 ca timeout so với 1 ca của lớp 0), nên con số per-class có thể lệch nhẹ.

Có điều gì chưa kiểm tra mà làm thêm sẽ chắc chắn hơn?

- Static-frame control** — bắt buộc, và là việc còn thiếu quan trọng nhất. Với temporal evidence ratio chỉ 0.176, khả năng cao model không dùng chuyển động. Cần biết chắc trước khi kết luận Cosmos "hiểu video".

- 2. **Temporal shuffle control** — đảo thứ tự frame. Nếu điểm không đổi → xác nhận model bỏ qua thông tin thời gian.
- 3. **Điều tra lớp 3 (Inflating the valve)** — 0/78 và chỉ được dự đoán 1 lần. Cần kiểm tra xem đây là do prompt mô tả nhãn không rõ, hay do model thật sự không nhận ra công đoạn này. Sửa mô tả nhãn trong prompt rồi chạy lại 78 video của lớp này là thí nghiệm rẻ.
- 4. **Giảm timeout** — 74.2% partial_timeout đang bóp méo kết quả. Nên thêm chỉ thị giới hạn độ dài suy luận, hoặc tăng timeout, rồi chạy lại.
- 5. **Chưa so với model video chuyên dụng nào khác trên cùng split** ngoài V-JEPA 2 (vốn có setup khác hẳn — có huấn luyện probe). Chưa có so sánh zero-shot ↔ zero-shot công bằng.
- 6. **Chưa có human baseline** — video chỉ 3.5 giây, cần biết người thường phân biệt được 7 công đoạn này chính xác đến đâu.

Nguồn dữ liệu và mã nguồn

Loại	Đường dẫn
Kết quả từng video	research/hatrec_cosmos3/outputs/analysis/hatrec_cosmos3_per_video.csv
Tổng hợp chấm sâu	.../outputs/analysis/deep_audit_summary.json
Chỉ số per-class	.../outputs/analysis/deep_per_class_metrics.csv
Phân loại lỗi	.../outputs/analysis/deep_error_taxonomy.csv
Phân tích ngữ nghĩa	.../outputs/analysis/semantic_content_summary.json , semantic_cue_confusion.csv
Báo cáo thô từng video	.../outputs/ui_reports/Cycle_*/ (78 thư mục)
Log chạy	.../outputs/ui_run_546.log
Runner	research/hatrec_cosmos3/run_ui.py
Audit dataset	.../outputs/dataset_audit.json
Notebook phân tích	research/hatrec_cosmos3/HATRec_Cosmos3_Insight_Analysis.ipynb

Hình nên gắn kèm khi trình bày:

outputs/analysis/deep_confusion_matrices.png , outputs/analysis/per_class_prf1.png ,
outputs/analysis/confidence_calibration.png , outputs/analysis/completion_status.png .

Report — V-JEPA 2 ViT-L × HATREC

🚨 **Cảnh báo đọc trước:** model đạt **100% (84/84)** trên tập test. Con số này **không được dùng để khẳng định năng lực**. Hai phép kiểm soát bắt buộc để loại trừ shortcut tính vẫn **chưa chạy**, và độ tương đồng thị giác test↔train là **0.9922**. Báo cáo này ghi nhận kết quả đồng thời giải thích vì sao chưa tin được.

Mục 1: Thông tin cơ bản

Mục	Nội dung
Tên model test	V-JEPA 2 ViT-L (facebook/vjepa2-vitl-fpc64-256), ~300M params
Dataset test trên	HATREC — video lắp ráp công nghiệp, phân loại 7 công đoạn
Quy mô	546 video / 78 cycle / 7 lớp cân bằng
Chia tập	54 cycle train / 12 cycle val / 12 cycle test → 378 / 84 / 84 dòng
Ngày test	2026-07-30
Người test	Sơn

Mục 2: Setup

Mục	Nội dung
Chạy ở đâu	Kaggle, GPU T4×2 (notebook assert đúng 2 GPU)
Chi phí	0 đ — free tier, không thuê server
Bản model	V-JEPA 2 ViT-L 300M, checkpoint facebook/vjepa2-vitl-fpc64-256
Số frame	64 frame/clip (cấu hình chính); có ablation 14 frame
Giải mã video	decord (cài trong notebook), transformers>=5.0.0
Notebook	research/hatrec_cosmos3/VJEPa2_HATREC_LeakageSafe.ipynb

⚠️ ĐÂY KHÔNG PHẢI ZERO-SHOT

Mục	Nội dung
Zero-shot?	KHÔNG
Có train gì không?	CÓ — linear probe. sklearn.linear_model.LogisticRegression , C = 0.01, huấn luyện trên embedding của 378 clip thuộc 54 cycle train
Encoder	Đóng băng — V-JEPA 2 không được cập nhật trọng số
Cái được huấn luyện	Chỉ lớp phân loại tuyến tính phía trên embedding

Ghi rõ điều này vì V-JEPA 2 về bản chất là **encoder biểu diễn/dự đoán**, không phải model ngôn ngữ. Nó **không tự sinh được câu trả lời trắc nghiệm hay lời giải thích tự do** — muốn ra nhãn thì bắt buộc phải gán

probe. Vì vậy kết quả ở đây **không so trực tiếp được** với các con số zero-shot của Cosmos 3 hay Qwen2-VL trên cùng dataset.

Ảnh xạ năng lực đã khai báo trong notebook:

- **B1** (phân loại trạng thái/công đoạn) — có claim, metric chính = macro-F1
- **B2** — *không* claim, vì các clip đã được cắt sẵn theo công đoạn
- **B10** — *không* claim, vì cycle giữ lại chỉ là kiểm soát tổng quát hoá, không phải tập OOD thật để đo khả năng abstain

Mục 3: Kiểm tra leak

Đây là model **có huấn luyện**, nên mục này áp dụng đầy đủ và là phần quan trọng nhất của báo cáo.

Kiểm tra	Giá trị	Trạng thái
Cycle nào trùng giữa train và test không	Chia theo cycle: 54 / 12 / 12, không cycle nào xuất hiện ở hai tập	✓ PASS
Tên file có lộ nhãn không	Đã trung tính hoá ở mức vật lý (physical_filename_neutralization: true)	✓ PASS
Trùng lặp byte tuyệt đối giữa các video	0	✓ PASS
Số mẫu có cosine > 0.999	0	✓ PASS
Cosine trung bình test → train gần nhất	0.9922	⚠ REVIEW
Cosine p95 test → train gần nhất	0.9959	⚠ REVIEW

Kết luận Mục 3: dữ liệu KHÔNG đủ độc lập để tin kết quả

Về mặt **quy trình**, mọi kiểm soát đều pass — không cycle trùng, không file lộ nhãn, không trùng byte, không mẫu nào vượt ngưỡng gần-trùng 0.999.

Nhưng về mặt **nội dung**, cosine trung bình 0.9922 nghĩa là mỗi clip test có một clip train gần như đồng nhất trong không gian biểu diễn. Cả 546 video được quay ở **cùng một trạm làm việc, cùng bố cục, cùng bộ dụng cụ, cùng thao tác lặp lại**. Việc chia theo cycle ngăn được leak *chính xác cùng một clip*, nhưng **không tạo ra được sự đa dạng thật** giữa train và test.

Nói cách khác: chia tập là hợp lệ, còn dataset thì không đủ đa dạng để phép chia đó có ý nghĩa. 100% ở đây có thể chỉ chứng minh rằng **7 công đoạn tách tuyến tính được trong không gian embedding của V-JEPA 2** — chứ không chứng minh model hiểu hành động hay chuyển động.

Mục 4: Kết quả chính

Dataset cân bằng (7 lớp), chance = 14.29%. Metric chính: **Macro-F1**.

4.1 Kết quả tổng

	Accuracy	Macro-F1	n
V-JEPA 2 ViT-L + linear probe	100.00% (Wilson CI 95.63–100.00)	1.0000	84
Baseline majority-class (blind)	14.29%	0.0357	84
Baseline nhãn xáo trộn (shuffled labels)	9.52%	0.0995	84
Baseline random-choice	14.29%	—	84
Chênh lệch vs majority	+85.71 điểm	+0.9643	

Cluster bootstrap macro-F1 CI 95% (bootstrap theo cycle, không theo dòng): [1.0, 1.0].

Cả hai negative control đều rơi về mức ngẫu nhiên → pipeline chấm điểm không có lỗi. Con số 100% là thật trong khuôn khổ thí nghiệm này, không phải bug đánh giá.

4.2 Theo từng lớp

Nhãn	Công đoạn	Support	Precision	Recall	F1
0	Assembling spring	12	1.0	1.0	1.0
1	White plastic	12	1.0	1.0	1.0
2	Screwing-1	12	1.0	1.0	1.0
3	Inflating valve	12	1.0	1.0	1.0
4	Black plastic	12	1.0	1.0	1.0
5	Screwing-2	12	1.0	1.0	1.0
6	Fixing cable	12	1.0	1.0	1.0

Đáng chú ý: **Screwing-1 và Screwing-2 phân biệt hoàn hảo** — đúng cặp mà Cosmos 3 nhầm nhiều nhất (14 lần). Cần giải thích: hai công đoạn này khác nhau về vị trí trong trình tự, nhưng cũng có thể khác nhau về chi tiết tĩnh (vị trí tay, trạng thái cụm lắp ráp tại thời điểm đó) — mà probe tuyến tính hoàn toàn có thể bắt được từ đặc trưng tĩnh.

4.3 Các cấu hình thí nghiệm

Cấu hình	Loại	Accuracy	Macro-F1
Cycle holdout — 64 frame	chính	1.0	1.0
Cycle holdout — 14 frame nhìn thấy	ablation	1.0	1.0
Random clip — 64 frame	so sánh rủi ro leak	1.0	1.0
Majority blind	negative control	0.1429	0.0357
Nhãn xáo trộn	negative control	0.0952	0.0995

⚠ **Ablation 14 frame cũng đạt 100%.** Giảm từ 64 xuống 14 frame — tức bỏ đi 78% thông tin thời gian — **không làm giảm điểm chút nào.** Đây là tín hiệu cảnh báo mạnh về shortcut tĩnh, xem Mục 5.

4.4 Hiệu chỉnh độ tin cậy

Chỉ số	Giá trị
ECE	0.0185
Multiclass Brier	0.00086

Hiệu chỉnh rất tốt — nhưng trên một bài toán mà model đúng 100% thì chỉ số này gần như không mang thông tin.

Mục 5: Kiểm tra shortcut

HATREC là **video** → mục này **có áp dụng**, và đây là chỗ báo cáo thất bại.

Kiểm tra	Trạng thái	Ghi chú trong file chẩn đoán
Static-frame (1 frame lặp lại 64 lần)	✗ CHƯA LÀM	MISSING – Required to separate static cues from motion
Temporal shuffle / đảo thứ tự frame	✗ CHƯA LÀM	MISSING – Required to test order sensitivity
Che vật thể / dụng cụ, can thiệp nền	✗ CHƯA LÀM	
Giữ riêng operator/trạm/sản phẩm	✗ CHƯA LÀM	Chưa có metadata
Chênh lệch 64 frame vs 14 frame	⚠ INCONCLUSIVE	0.0 – No degradation with 14 visible frames

Chưa có số static-frame nên không áp được tiêu chí <5% / >20–30% của template.

Nhưng bằng chứng gián tiếp đã đủ để nghi ngờ về giả thuyết shortcut:

- Ablation 14 frame = 100%, y hết 64 frame.** Theo đúng logic của template: nếu giảm mạnh thông tin thời gian mà điểm không đổi thì "model có thể đang đoán dựa trên đặc điểm hình ảnh tĩnh, không phải chuyển động thật". Đây chưa phải static-frame test nhưng đi cùng hướng.
- Cosine test → train 0.9922.** Mỗi clip test có bản gần-song sinh trong tập train.
- Random clip cũng đạt 100%** — cách chọn đoạn clip không ảnh hưởng gì.

Đánh giá: ba dấu hiệu cùng chỉ về một hướng — kết quả 100% nhiều khả năng đến từ **đặc trưng tĩnh của khung hình** (bố cục bàn, vật thể đang có mặt, trạng thái cụm lắp ráp), chứ không phải từ hiểu chuyển động. Chỉ static-frame control mới kết luận được dứt điểm.

Mục 6: Ví dụ lỗi cụ thể

Model đúng 84/84 — không có ca sai nào để liệt kê.

Việc không thể hoàn thành mục này **chính là phát hiện quan trọng nhất của báo cáo**. Một benchmark mà model đạt trần tuyệt đối thì không còn khả năng phân biệt model tốt với model kém, và không cung cấp được thông tin gì để cải thiện.

Thay vào đó, dưới đây là **5 thiếu sót của chính thí nghiệm** — đóng vai trò tương đương "danh sách lỗi" cho mục này:

Thiếu sót 1 — Không có static-frame control

- **Cần làm gì:** lấy 1 frame giữa clip, lặp lại thành 64 frame, chạy lại probe.
- **Kỳ vọng phân biệt:** nếu vẫn $\approx 100\%$ → xác nhận shortcut tĩnh, kết quả hiện tại vô hiệu. Nếu tụt $>20-30\%$ → model thật sự dùng chuyển động.
- **Vì sao quan trọng nhất:** đây là phép kiểm duy nhất tách được hai giả thuyết đang cạnh tranh.

Thiếu sót 2 — Không có temporal shuffle control

- **Cần làm gì:** xáo trộn/đảo ngược thứ tự frame rồi chạy lại.
- **Kỳ vọng:** nếu điểm không đổi → model bỏ qua hoàn toàn chiều thời gian.

Thiếu sót 3 — Tương đồng test↔train 0.9922 chưa được xử lý

- **Cần làm gì:** chia tập theo operator / trạm / ngày quay thay vì chỉ theo cycle, hoặc kiểm thử trên dây chuyền khác.
- **Vấn đề:** chia theo cycle không tạo được sự khác biệt phân phối thật.

Thiếu sót 4 — Không lưu xác suất từng mẫu

- **Cần làm gì:** lưu `predict_proba` cho từng clip.
- **Vấn đề:** không có nó thì không vẽ được reliability diagram, không phân tích được abstention — vốn là yêu cầu của B10 (mà notebook đã đúng khi *không* claim B10).

Thiếu sót 5 — Không có ablation không-chuyển-động ở mức đặc trưng

- **Cần làm gì:** che vật thể/dụng cụ hoặc thay nền, giữ nguyên chuyển động.
- **Vấn đề:** chưa biết model bám vào vật thể hay bám vào hành động.

Mục 7: Kết luận cuối cùng

Dataset: HATREC (probe tuyến tính trên 12 cycle giữ lại, $n = 84$)

Theo đúng con số:

- ☒ **Model này THẮNG RÕ RÀNG so với baseline đơn giản** — Macro-F1 1.0 vs 0.0357; accuracy 100% vs 14.29%.
- ☐ NGANG BẰNG
- ☐ THUA

Nhưng kết luận về hiệu lực (đề lên kết luận trên):

🚨 KẾT QUẢ KHÔNG TIN CẬY ĐƯỢC — không dùng để claim năng lực.

Ba lý do: (1) thiếu static-frame control, (2) ablation 14 frame cho gap 0.0, (3) cosine test→train 0.9922.

Điều thí nghiệm này chứng minh được: **7 công đoạn HATREC tách tuyến tính được trong không gian biểu diễn của V-JEPA 2.**

Điều thí nghiệm này **không** chứng minh được: V-JEPA 2 hiểu chuyển động, hiểu trình tự thời gian, hay tổng quát hoá sang đây chuyển khác.

Mọi con số HATREC báo cáo ra ngoài từ nay phải kèm ba điều kiện: tên file đã trung tính hoá, chia tập theo cycle/participant, **và có static-frame control**. Hai điều kiện đầu đã đạt; điều kiện thứ ba chưa.

Mục 8: Lưu ý / giới hạn

Mẫu test có đủ lớn không?

Hơi nhỏ. 84 clip từ 12 cycle. Wilson CI cận dưới là 95.63% — nghĩa là kể cả với 84/84 đúng, thống kê chỉ đảm bảo được "ít nhất 95.6%". Quan trọng hơn: 12 cycle là **12 đơn vị độc lập thật sự**, không phải 84. Cluster bootstrap đã tính đúng theo cycle và vẫn ra [1.0, 1.0], nhưng nền tảng vẫn chỉ là 12 cụm.

Có phát hiện leak không? Kết quả Mục 4 có đáng tin?

Leak **theo quy trình**: không — mọi kiểm soát pass. Leak **theo nội dung**: có vấn đề — cosine 0.9922 cho thấy test và train gần như cùng phân phối thị giác.

Kết quả Mục 4 KHÔNG đáng tin như một tuyên bố về năng lực. Nó đáng tin như một tuyên bố hẹp hơn: "với dữ liệu cùng trạm làm việc này, probe tuyến tính trên embedding V-JEPA 2 phân loại được 7 công đoạn".

Có điều gì chưa kiểm tra mà làm thêm sẽ chắc chắn hơn?

1. **Static-frame control** — ưu tiên tuyệt đối. Rẻ, nhanh, và quyết định toàn bộ hiệu lực của báo cáo này.
2. **Temporal shuffle control** — ưu tiên hai, cùng lý do.
3. **Che vật thể / can thiệp nền** — tách "nhận ra dụng cụ" khỏi "nhận ra hành động".
4. **Chia tập theo operator/trạm/sản phẩm** — cần metadata, hiện chưa có.
5. **Lưu xác suất từng mẫu** — để làm reliability diagram và phân tích abstention.
6. **Cần một benchmark khó hơn.** HATREC ở trần 100% không còn giá trị phân biệt. Muốn đo năng lực video thật cần dataset có đa dạng trạm/người/sản phẩm, hoặc chuyển sang bài toán chưa cắt sẵn (phát hiện ranh giới công đoạn — chính là B2 mà notebook đã đúng khi không claim).

Nguồn dữ liệu và mã nguồn

Loại	Đường dẫn
Metrics	research/hatrec_cosmos3/vjepa2_hatrec_results/hatrec_vjepa2_metrics.json
Dự đoán	.../vjepa2_hatrec_results/hatrec_vjepa2_predictions.csv
Kết luận nghiên cứu	.../vjepa2_hatrec_results/deep_analysis/VJEPA2_HATREC_RESEARCH_VERDICT.md
Chẩn đoán leak/shortcut	.../deep_analysis/leakage_shortcut_diagnostics.csv
Báo cáo per-class	.../deep_analysis/per_class_report.csv
Khoảng tin cậy	.../deep_analysis/uncertainty_intervals.csv
Notebook chạy	research/hatrec_cosmos3/VJEPA2_HATREC_LeakageSafe.ipynb
Notebook phân tích	.../vjepa2_hatrec_results/VJEPA2_HATREC_Deep_Analysis.executed.ipynb

Hình nên gắn kèm khi trình bày:

deep_analysis/01_results_and_controls.png , deep_analysis/03_similarity_audit.png (hình quan trọng nhất — thể hiện phân bố cosine 0.99), hatrec_vjepa2_analysis.png .