

Báo cáo Phase 1 — Chỉ mục

Người test: Sơn · Cập nhật: 2026-08-01 · Repo: <https://github.com/ahnsown/mini-world-model>

Mỗi cặp (model × dataset) một báo cáo riêng, viết theo cấu trúc 8 mục thống nhất của team.

#	Báo cáo	Model	Dataset	Độ phủ
01	Qwen2-VL-2B × MMAD	Qwen2-VL-2B-Instruct	MMAD	39,670/39,670 (100%)
02	Cosmos 3 Nano × MMAD	Cosmos 3 Nano Reasoner	MMAD	622/39,670 (1.57%)
03	Cosmos 3 Nano × HATREC	Cosmos 3 Nano Reasoner	HATREC	546/546 (100%)
04	V-JEPA 2 ViT-L × HATREC	V-JEPA 2 ViT-L 300M	HATREC	84 clip test (12 cycle)

Bảng tổng hợp chung

Model	Dataset	Metric chính	Baseline cùng dữ liệu	Thắng/Ngang/Thua	Shortcut / Leak?
Qwen2-VL-2B	MMAD (đủ 4 nguồn)	Macro-F1 0.650 · micro 64.73%	majority-letter 30.38% (F1 0.117)	THẮNG rõ ràng	Không leak protocol. Chưa test blind-image
Qwen2-VL-2B	MMAD — riêng subtask Anomaly Detection	F1 0.584 · recall 0.481	"luôn nói có lỗi" F1 0.756	THUA	Miss rate 51.9%
Cosmos3-Nano (BNB8, Kaggle T4×2)	MMAD (380 câu, chỉ MVTec-AD)	Macro-F1 0.746 · micro 73.16%	majority-letter 35.53%	THẮNG rõ ràng	Không leak. Thiên lệch độ phủ nặng
Cosmos3-Nano (endpoint chính thức)	MMAD (221 câu, chỉ MVTec-AD)	Macro-F1 0.496 · micro 49.77%	majority-letter 51.13%	THUA	như trên
Cosmos3-Nano	MMAD — riêng subtask Anomaly Detection	F1 0.250 · recall 0.143	"luôn nói có lỗi" F1 0.830	THUA nặng	Miss rate 85.7%
Cosmos3-Nano	HATREC (classification)	Macro-F1 0.216 · acc 23.63%	majority-class F1 0.036	THẮNG (nhưng không dùng được)	Không leak. Chưa test static-frame; bằng chứng thời gian chỉ 17.6%
V-JEPA 2 ViT-L (🚩 có probe, không zero-shot)	HATREC	Macro-F1 1.0 · acc 100%	majority blind F1 0.036	Thắng về số — KHÔNG TIN CẬY ĐƯỢC	Leak quy trình PASS, nhưng similarity 0.9922 + thiếu static-frame
GPT-4o (tham chiếu từ paper MMAD)	MMAD	~74.9%	—	Cao hơn nhiều model open-source	Paper có human baseline để đối chiếu

Ba kết luận cần nhấn mạnh khi trình bày

1. So sánh Cosmos vs Qwen trên MMAD phải khớp nguồn dữ liệu

Toàn bộ 601 record parse-valid của Cosmos đều thuộc **MVTec-AD** — đúng nguồn dễ nhất trong 4 nguồn của MMAD.

So sánh	Cosmos 3 Nano	Qwen2-VL-2B	Kết quả
❌ Sai — Cosmos (MVTec-AD) vs Qwen (cả 4 nguồn)	73.16%	64.73%	"Cosmos hơn 8.4 điểm"
✅ Đúng — cả hai trên MVTEC-AD	73.16%	75.25%	Qwen hơn 2.1 điểm

Bảng đặt 73.16% cạnh 64.73% là **so sánh không hợp lệ** và đảo ngược kết luận. Chênh giữa nguồn dễ nhất (MVTec-AD 75.25%) và khó nhất (MVTec-LOCO 55.22%) lên tới 20 điểm.

2. Cả hai VLM đều thất bại đúng ở chỗ quan trọng nhất

Trên subtask **Anomaly Detection** — sát nhất với bài toán B3 của công ty — cả hai đều **thua baseline ngu**:

Model	Recall	F1	Baseline F1	Miss rate
Qwen2-VL-2B	0.481	0.584	0.756	51.9%
Cosmos 3 Nano	0.143	0.250	0.830	85.7%

Cả hai đều thiên lệch mạnh về phía "không có lỗi". Accuracy tổng che mất điều này — đúng lý do template cấm dùng accuracy làm metric chính cho dữ liệu mất cân bằng.

3. Kết quả 100% của V-JEPA 2 chưa được phép công bố như một thành tựu

Ablation 14 frame cũng cho 100% (gap 0.0), cosine test→train 0.9922, và static-frame control **chưa chạy**. Điều chứng minh được chỉ là: 7 công đoạn HATREC **tách tuyến tính được** trong không gian embedding của V-JEPA 2.

Còn thiếu — chưa có báo cáo

Model × Dataset	Trạng thái	Ghi chú
Cosmos3-Nano × PIADE/ALPI (B0 + B5)	❌ 0%	Đầu việc bắt buộc, ưu tiên cao nhất theo handoff §12. Chưa có dữ liệu, script hay thư mục nào trong workspace
Qwen2-VL-2B × HATREC	❌ Không có dữ liệu trên máy	Con số 15.02% trong bảng team là của người khác
Cosmos3-Nano × MMAD — 3 nguồn còn lại	❌ Chưa chạy	GoodsAD, VisA, MVTEC-LOCO đều n = 0

Việc bắt buộc phải bổ sung cho các báo cáo đã có

Xếp theo tỉ lệ giá trị/chi phí:

1. **Static-frame control cho cả hai báo cáo HATREC** (03, 04) — rõ, nhanh, quyết định hiệu lực của cả hai. Với V-JEPA đây là điều kiện tiên quyết để con số 100% có ý nghĩa.
 2. **Chạy 100 câu MMAD giống hệt nhau trên cả hai backend Cosmos** — để giải thích chênh lệch 73.16% vs 49.77%. Chưa hiểu nguyên nhân thì mọi record gộp về sau đều mang lỗi hệ thống.
 3. **Blind-image control trên ~500 câu MMAD** — cho cả Qwen và Cosmos, xác nhận model thật sự dùng ảnh.
 4. **Mở rộng Cosmos sang MVTec-LOCO** — nguồn khó nhất, cho cận dưới thực tế.
 5. **Lưu probability outputs** ở mọi lần chạy sau — hiện chưa report được ECE/abstention cho hai model MMAD.
 6. **Temporal shuffle control** cho HATREC.
-

Ghi chú về quy trình

- Mọi baseline trong các báo cáo này được **tính lại bằng code trên đúng tập record mà model đã trả lời**, không mượn từ nguồn khác và không lấy từ paper.
- Metric chính là **Macro-F1** ở mọi nơi dữ liệu mất cân bằng; accuracy chỉ báo kèm khi đó là protocol công bố của dataset (MMAD).
- Theo lưu ý chung của team: **chờ khung codebase chung từ Quỳnh Anh** trước khi viết code cho các lần chạy tiếp theo, để định dạng kết quả thống nhất và gộp được. Bốn báo cáo này viết từ dữ liệu **đã thu thập xong**, không phát sinh code chạy model mới.
- Chi phí đến thời điểm này: **0 đ** — toàn bộ chạy trên Kaggle free tier và NVIDIA Build free tier, không thuê server.